Estadística para la Ciencia de Datos

PIA

Introducción

El término alemán fue introducido originalmente en 1749 y hacía referencia al análisis de datos del Estado. La palabra “estadística” procede del vocablo “estado”, pues era función principal de los gobiernos de los estados establecer registros de población, nacimientos, defunciones, impuestos, cosechas, etc.

La necesidad de poseer datos sobre la población y sus condiciones materiales de existencia ha debido existir desde que se establecieron sociedades humanas organizadas.

Aplicación en el ámbito de los negocios

La toma de decisiones está en la esencia de los negocios. Dirigir una empresa es tomar decisiones, muchas veces bajo presión, con información desordenada y en un contexto de incertidumbre. La estadística es la ciencia que permite tomar decisiones en condiciones de variabilidad o de incertidumbre.

La toma de decisiones en condiciones de incertidumbre da lugar a algunos de los problemas más comunes en las empresas. Cómo dijo Peter Drucker, gurú del management del siglo XX: “Si no lo puedes medir, no lo puedes mejorar”. Esto implica una desventaja seria para los procesos de mejora de las empresas.

Datos, información y estadística

Datos, información y conocimiento son conceptos distintos.

Podemos definir los datos como el conjunto de observaciones o hechos que, una vez recogidos, organizados y procesados, se transforman en información o conocimiento. De la misma forma que el petróleo crudo es la materia prima para obtener gasolina o la madera es materia prima para obtener papel, los datos son la materia prima de la que se obtiene información.

Datos, información y estadística

Datos: hechos o valores crudos, sin procesar ni interpretar. No tienen contexto por sí mismos.

- 27, 32, 45.
- 25 ºC.

Información: Surge cuando los datos se organizan o se les da contexto, de manera que empiezan a tener sentido y pueden ser interpretados.

- “La temperatura en Madrid hoy es de 25 °C.”
- “Las ventas del producto X en enero fueron 27 unidades, en febrero 32 y en marzo 45.”

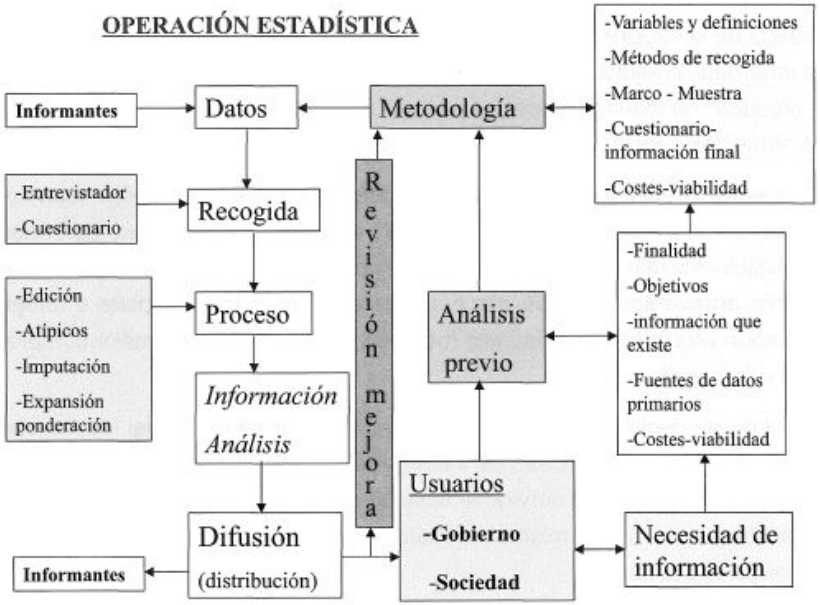
Conocimiento: Se produce cuando la información se analiza, interpreta y se combina con experiencia o comprensión, permitiendo tomar decisiones o generar acciones.

- “Si la temperatura en Madrid es de 25 °C en abril, es probable que la primavera sea más cálida de lo normal; conviene preparar campañas de venta de aire acondicionado.”
- “Las ventas del producto X han aumentado de 27 a 45 en tres meses. Esto indica una tendencia creciente, por lo que deberíamos aumentar la producción.”

Datos, información y estadística

Todos los días en los medios de comunicación pueden encontrarse noticias basadas en datos estadísticos: desempleo, precios de consumo, encuestas electorales, sondeos de opinión, audiencias de televisión, radio y otros medios, gastos de los hogares, inversión publicitaria, cotizaciones de bolsa, datos macroeconómicos, ...

El método estadístico



Conceptos básicos

Población: Es el conjunto total de individuos sobre los que se quiere estudiar unos datos determinados.

- Si queremos estudiar la estatura media de los españoles, la población la constituirán todos los españoles.
- Si queremos estudiar la nota media de Matemáticas en 1º de la ESO en el IES Polígono Sur, la población la constituyen todos los alumnos de 1º de ESO del instituto.

Conceptos básicos

Muestra: Cuando la población es muy grande (por ejemplo, todos los españoles) o difícil de estudiar (por ej., la calidad de las bombillas o la deformación de los coches en un choque) se elige una muestra, que es una parte de la población representativa de la misma, es decir, con unas características similares. Ha de elegirse al azar.

- Para estudiar la estatura de los españoles en la muestra deberíamos incluir a individuos de diferentes edades, de diferente estrato social y económico, de distinto lugar geográfico, de ambos sexos.

Tamaño de la muestra: Número de elementos u observaciones que forman la muestra.

Conceptos básicos

Encuesta: Procedimiento que nos permite obtener los datos para hacer un estudio de ellos (puede ser oral o escrita).

Estadístico: Medida descriptiva de la muestra y que estima el parámetro de la población.

- Media, mediana, moda…

Conceptos básicos

Variable estadística: Es el dato o característica que se quiere estudiar.

- La estatura.
- La calidad de las bombillas.
- La nota de Matemáticas.

Existen dos tipos de variables:

- ❏ Cuantitativas
- ❏ Cualitativas.

Conceptos básicos

Variables

Observaciones

Datos

Cliente	Gasto tarjeta de crédito	Edad	Sexo	Ocupación	Ingresos mensuales
1	400	20	Hombre	Estudiante	400
2	1270	56	Hombre	Trabajador	1500
3	567	76	Mujer	Jubilada	1200
4	876	32	Hombre	Desempleado	700
5	984		Mujer	Trabajadora	2000
6	2456	45	Hombre	Desempleado	1000
7	1345	54	Mujer	Trabajadora	2500
8	1876	43	Mujer	Estudiante	450
9	345	39	Mujer	Trabajadora	1800

Conceptos básicos

Variable cuantitativa: Es aquella que estudia algo que se expresa mediante números.

- La estatura, la nota de Matemáticas, etc.

Puede ser:

- ❏ Discreta.
- ❏ Continua.

Conceptos básicos

Variable cuantitativa discreta: Es aquella que toma valores aislados o contables, generalmente números enteros. No admite valores intermedios entre un número y otro.

- Número de hijos en una familia (0, 1, 2, 3… nunca 2,5).
- Número de autos que pasan por un semáforo en 1 hora.
- Cantidad de goles en un partido.

Variable cuantitativa continua: Es aquella que puede tomar infinitos valores dentro de un intervalo, incluyendo decimales. Son medidas y no simples conteos.

- La estatura de una persona (1,72 m; 1,725 m; 1,7254 m…).
- La temperatura (22,5 °C; 22,56 °C…).
- El peso de una fruta (150 g; 150,3 g…).

Conceptos básicos

Variable cualitativas o categóricas: son aquellas que no se expresan en números, sino en categorías o atributos. Sirven para clasificar o describir cualidades de los elementos.

Existen dos tipos:

Nominales: Solo nombran o diferencian categorías, sin ningún orden.

- Color de ojos (azul, verde, café).
- Nacionalidad (mexicana, argentina, peruana).
- Estado civil (soltero, casado, divorciado).

Ordinales: Además de clasificar, tienen un orden jerárquico, aunque no se puede medir la distancia exacta entre las categorías.

- Nivel educativo (primaria, secundaria, universidad, posgrado).
- Escala de satisfacción (muy insatisfecho, insatisfecho, neutral, satisfecho, muy satisfecho).
- Rangos militares (soldado, cabo, sargento, teniente…).

¿Tipo de variable?

1. Peso de una manzana
2. Número de hermanos
3. Nacionalidad
4. Tiempo en correr 100 metros
5. Nivel educativo alcanzado
6. Número de mascotas en casa
7. Color favorito
8. Edad de una persona
9. Estado civil
10. Temperatura de una ciudad

Distribución de frecuencias

Una primera forma de resumir la información es mediante la tabulación de los datos, o dicho de otro modo: recoger la información de la muestra resumida en una tabla en la que a cada valor de la variable se le asocian determinados números que representan el número de veces que ha aparecido, su proporción con respecto a otros valores de la variable, etc.

A esta tabla se le denomina **tabla de frecuencias**.

Distribución de frecuencias

Una tabla de frecuencias para una variable es una tabla en la que se contabiliza para cada valor distinto observado la frecuencia observada (absoluta o relativa) de individuos que toman dicho valor.

Distribución de frecuencias

Variable (Notas) xi	Frecuencia (Alumnos) ni	Frecuencia relativa fi	Frecuencia acumulada Ni	xi · ni
0	2	0,07	2	0
1	2	0,07	4	2
2	1	0,03	5	2
3	4	0,13	9	12
4	2	0,07	11	8
5	3	0,1	14	15
6	3	0,1	17	18
7	4	0,13	21	28
8	3	0,1	24	24
9	4	0,13	28	36
10	2	0,07	30	20
	30	1		165

Distribución de frecuencias

Frecuencia absoluta

La frecuencia absoluta de una variable estadística es el número de veces que aparece en la muestra dicho valor de la variable.

Frecuencia relativa

La frecuencia absoluta es una medida que está influida por el tamaño de la muestra. Al aumentar el tamaño de la muestra aumentará también el tamaño de la frecuencia absoluta. Esto hace que no sea una medida útil para poder comparar. Para esto es necesario introducir el concepto de frecuencia relativa, que es el cociente entre la frecuencia absoluta y el tamaño de la muestra.

Distribución de frecuencias

Frecuencia absoluta acumulada

Para poder calcular este tipo de frecuencias hay que tener en cuenta que la variable estadística ha de ser cuantitativa o cualitativa ordenable. La frecuencia absoluta acumulada de un valor de la variable es el número de veces que ha aparecido en la muestra un valor menor o igual que el de la variable.

Frecuencia relativa acumulada

Al igual que en el caso anterior, la frecuencia relativa acumulada es la frecuencia absoluta acumulada dividida por el tamaño de la muestra.

Medidas de posición centrales

La descripción numérica de una variable cuantitativa se realiza mediante una medida de tendencia central y una medida de dispersión.

Las medidas de tendencia central son un valor alrededor del cual se concentran los datos. Estas son la media aritmética, la mediana y la moda.

Medidas de posición centrales

La **media** es el promedio de las observaciones, es decir: la suma de todos los valores de la variable dividida entre el número total de elementos:

Si la edad de los nueve primeros sujetos de la muestra fueran 20, 56, 76, 32, 23, 45, 54, 43, 39 años, la media de edad sería:

$$media\ (x) = \frac{20 + 56 + 76 + 32 + 23 + 45 + 54 + 43 + 39}{9} = 43{,}11\ años$$

La media es 43,11 años.

Medidas de posición centrales

La media es la medida de tendencia central más utilizada. Su principal desventaja es que está fuertemente afectada por los valores extremos.

Si los días de uso mensual de la tarjeta de crédito de nueve clientes fueran 1, 3, 4, 2, 3, 4, 2, 3 y 1, la media sería 2,6 días. Sin embargo, el hecho de cambiar el último 1 por un 25 cambiaría drásticamente la media, que pasaría a ser 5,2 días, un valor que no es representativo de los días de uso de tarjeta de crédito de los clientes. Por eso, en presencia de valores extremos, es preferible utilizar la mediana como medida de tendencia central.

Medidas de posición centrales

La **mediana** es el valor que divide la distribución de los datos en dos grupos de igual número de elementos (individuos), de modo que en el primer, todos los datos sean menores o iguales que la mediana, y en el otro grupo, todos los datos sean mayores o iguales. Por lo tanto, es una cantidad que indica orden.

El cálculo de la mediana varía en función de si el número de observaciones es par o impar:

Medidas de posición centrales

Número de observaciones impar

Si las edades de los nueve primeros clientes de la muestra fueran 20, 56, 76, 32, 23, 45, 54, 43, 39 años, se ordenarían las edades de menor a mayor: 20, 23, 32, 39, 43, 45, 54, 56, 76. Y se selecciona el valor central como la mediana. Mediana=43 años.

Número de observaciones par

Si las edades de los diez primeros clientes de la muestra fueran 20, 56, 76, 32, 23, 45, 54, 43, 39, 34, se ordenan las edades de menor a mayor: 20, 23, 32, 34, 39, 43, 45, 54, 56, 76. Y se calcula la mediana como la media de los dos valores centrales:

Mediana=(39+43)/2=41

Medidas de posición centrales

La **moda** es el valor de la variable que más veces se repite, es decir, el valor que ocurre con mayor frecuencia.

Si las edades de los nueve primeros clientes de la muestra fueran 20, 56, 76, 32, 23, 45, 54, 56 y 39, la moda sería 56 años.

Medidas de posición no centrales

Son medidas de localización similares a la mediana. Se utilizan para determinar el valor de la variable que ocupará la posición (en tanto por ciento) que interese respecto de todo el conjunto de observaciones.

Medidas de posición no centrales

Percentiles

Se puede decir que los percentiles son unas medidas de posición que dividen la distribución en un cierto número de partes. Si se ordenan los datos de menor a mayor, se define el percentil “i” como el valor que deja a su izquierda el “i %” del total de observaciones.

Cuartiles

Los percentiles 25, 50 y 75 se denominan primer, segundo (o mediana) y tercer cuartil. A continuación, se presenta el procedimiento para llevar a cabo el cálculo de los percentiles 25 y 75 de las edades de los primeros 12 clientes de la muestra: 20, 56, 76, 32, 23, 45, 54, 43, 39, 34, 44, 38.

Medidas de posición no centrales

Percentil 25 (o primer cuartil)

Si se ordenan los datos de menor a mayor, el percentil 25 será aquel valor que deja a su izquierda el 25 % del total de observaciones y a su derecha el 75 % de estas.

Se ordenan los datos de menor a mayor: 20, 23, 32, 34, 38, 39, 43, 44, 45, 54, 56, 76.

Se identifica el valor que deja a su izquierda el 25 % de las observaciones, que son tres observaciones: 34. Y el valor que deja a su derecha el 75 % de estas, o sea: 32. El percentil 25 es el promedio de ambas observaciones:

Percentil 25=(34+32)/2=33

Medidas de posición no centrales

Percentil 75 (o tercer cuartil)

Si se ordenan los datos de menor a mayor, el percentil 75 será aquel valor que deja a su izquierda el 75 % de las observaciones y a su derecha el 25 % de las mismas.

Se ordenan los datos de menor a mayor: 20, 23, 32, 34, 38, 39, 43, 44, 45, 54, 56, 76.

Se identifica el valor que deja a su izquierda el 75 % de las observaciones, es decir, nueve: 54. Y el valor que deja a su derecha el 25 % de las observaciones, que son tres: 45. El percentil 75 se calcula como el promedio de ambas observaciones:

Percentil 75=(54+45)/2=49,5

Medidas de dispersión absolutas: varianza y desviación típica

Se plantea encontrar una medida de dispersión en la que participen todos los datos de la muestra. Parece conveniente calcular la diferencia entre cada edad y la edad media (41,4 años):

Cliente	Edad	Edad - edad media
1	20	-21,4
2	56	+14,6
3	76	+34,6
4	32	-9,4
5	23	-18,4

Medidas de dispersión absolutas: varianza y desviación típica

Si calculamos la media de las diferencias veréis que es 0.

La media de las diferencias es 0; sin embargo, las diferentes edades tomadas de manera independiente sí que presentan una dispersión significativa respecto a la edad media (41,4 años). Esto sucede porque las diferencias positivas y negativas se compensan entre sí.

Para evitar valores negativos de las diferencias, se elevan al cuadrado las diferencias entre cada edad y la edad media. En ese caso obtendremos el valor 459, que representa la **varianza**.

Medidas de dispersión absolutas: varianza y desviación típica

Cliente	Edad	Edad - edad media	(Edad - edad media)²
1	20	-21,4	457,96
2	56	+14,6	213,15
3	76	+34,6	1197,16
4	32	-9,4	88,36
5	23	-18,4	338,56

Medidas de dispersión absolutas: varianza y desviación típica

La **desviación típica** es la medida de dispersión más utilizada. Es la raíz cuadrada de la varianza. Expresa la dispersión de los datos respecto a la media y se expresa en las mismas unidades de medida que la variable original.

En este ejemplo, la desviación estándar sería:

$$Desviancián\ estándar = \sqrt{459{,}0} = 21{,}4$$

Medidas de dispersión relativas: coeficiente de variación

Se usan en el caso de que el problema sea comparar la variabilidad de dos poblaciones con medidas diferentes (variables con unidades diferentes).

Por ejemplo, se quiere comparar la dispersión entre la altura de 50 alumnos de una clase y su peso. Para comparar la altura, se podría utilizar como unidad de medida metros y centímetros y para el peso el kilogramo. O si se quiere comparar el peso de escarabajos, en miligramos, y el de los elefantes en toneladas. Se puede considerar un coeficiente adimensional, que es el **coeficiente de variación**.

Medidas de dispersión relativas: coeficiente de variación

Se define del siguiente modo (como un porcentaje):

$$Coeficiente\ de\ variación = \frac{desviación\ estándar}{media} x100$$

- Solo se debe calcular para variables con todos los valores positivos.
- Todo índice de variabilidad es esencialmente no negativo.
- Las observaciones pueden ser positivas o nulas, pero su variabilidad debe ser siempre positiva. De ahí que solo se deba calcular el coeficiente de variación con variables positivas.
- La mayor dispersión corresponderá al valor del coeficiente de variación mayor.

Tipificación o normalización

Se llama tipificación al proceso de restar la media y dividir entre su desviación típica a una variable.

$$z = \frac{valor\ variable - media}{desviación\ estándar}$$

De este modo, se obtiene una nueva variable de media 0 y desviación estándar 1, que se denomina variable tipificada.

Esta nueva variable carece de unidades y permite hacer comparables dos medidas que en un principio no lo son por aludir a conceptos diferentes.

La vinculación entre variables estadísticas

Al igual que se hacía con las variables unidimensionales, en las que cuando el número de valores observados de la variable era grande, en vez de enumerarlos se construía una tabla de frecuencias; cuando se trabaja con variables bidimensionales, si el número de pares (x, y) observados es grande, en vez de enumerarlos, se recurre a una tabla de frecuencias de doble entrada en la que cada celda contiene el número de veces que se observa cada pareja de valores (x, y). En los siguientes apartados se verán sus características en detalle.

$X\ Y$	y_1	$\cdots$	y_j	$\cdots$	y_s	
x_1	n_{11}	$\cdots$	n_{1j}	$\cdots$	n_{1s}	$n_{1\cdot}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_i	n_{i1}	$\cdots$	n_{ij}	$\cdots$	n_{is}	$n_{i\cdot}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_r	n_{r1}	$\cdots$	n_{rj}	$\cdots$	n_{rs}	$n_{r\cdot}$
	$n_{\cdot 1}$	$\cdots$	$n_{\cdot j}$		$n_{\cdot s}$	n

La vinculación entre variables estadísticas

Si son variables numéricas, la tabla suele llamarse **tabla de correlación**.

Si las dos variables son atributos o categorías, la tabla suele llamarse **tabla de contingencia**.

La vinculación entre variables estadísticas

Ejemplo en R: a continuación se muestra la tabla de distribución de frecuencias conjunta, absoluta y relativa, para las variables relacionadas con el tipo de campaña aplicada y con el estado civil del cliente.

```
#Tabla frecuencia absoluta

banco$campaign[banco$campaign >=5] <- 5
tabla<- table(banco$campaign, banco$marital)
addmargins(tabla)

##
##     divorced married single  Sum
## 1       222    1033    479 1734
## 2       139     790    335 1264
## 3        61     363    134  558
## 4        34     209     82  325
## 5        72     402    166  640
## Sum     528    2797   1196 4521

#Tabla frecuencia relativa

tabla<- prop.table(table(banco$campaign, banco$marital))
addmargins(tabla)

##
##       divorced   married    single       Sum
## 1  0.04910418 0.22848927 0.10595001 0.38354346
## 2  0.03074541 0.17474010 0.07409865 0.27958416
## 3  0.01349259 0.08029197 0.02963946 0.12342402
## 4  0.00752046 0.04622871 0.01813758 0.07188675
## 5  0.01592568 0.08891838 0.03671754 0.14156160
## Sum 0.11678832 0.61866844 0.26454324 1.00000000
```

Distribuciones marginales

A veces, en las tablas de doble entrada interesa estudiar aisladamente cada una de las variables. De esta manera, se obtienen dos distribuciones unidimensionales, que serían las correspondientes a cada una de las variables X e Y. A estas distribuciones se les llama distribuciones marginales.

Ejemplo en R: la tabla siguiente muestra las frecuencias marginales de la variable correspondiente al estado civil del ejemplo anterior.

```
#Frecuencia condicional por variable estado civil
addmargins(prop.table(table(banco$marital)))

##
##  divorced   married    single       Sum
## 0.1167883 0.6186684 0.2645432 1.0000000
```

Tablas de contingencia

Una tabla de contingencia es una de las formas más comunes de resumir datos categóricos o una variable cualitativa y otra cuantitativa. En general, el interés se centra en estudiar si existe alguna asociación entre una variable denominada fila y otra variable denominada columna y se calcula la intensidad de dicha asociación.

Es una tabla de doble entrada en la que en las filas se ubican las modalidades de una de las variables (atributos) y en las columnas las del otro; en las celdas resultantes del cruce de las filas y las columnas se incluye el número de elementos de la distribución que presentan ambas modalidades.

Tablas de contingencia

Las tablas de contingencia se leen fila por fila y de derecha a izquierda y se interpretan los porcentajes. Hay que distinguir entre:

Variable explicativa: Variable independiente, que irá en filas.

Variable de respuesta: Variable dependiente, que irá en columnas.

Si no hay diferencias de respuestas, es decir, si los porcentajes en una misma fila son muy similares es que no hay relación entre las variables.

Tablas de contingencia

Ejemplo en R: en este ejemplo se puede analizar qué grado de influencia tienen los estudios de los clientes de un banco a la hora de contratar un depósito por teléfono.

```
library(summarytools)

ctable(banco$education,banco$y)

## Cross-Tabulation, Row Proportions
## education * y
## Data Frame: banco
## ----------- --- ------------- ------------ --------------
##           y          no         yes          Total
##   education
##     primary       614 (90.6%)   64 ( 9.4%)   678 (100.0%)
##   secondary      2061 (89.4%)  245 (10.6%)  2306 (100.0%)
##    tertiary      1157 (85.7%)  193 (14.3%)  1350 (100.0%)
##     unknown       168 (89.8%)   19 (10.2%)   187 (100.0%)
##       Total      4000 (88.5%)  521 (11.5%)  4521 (100.0%)
## ----------- --- ------------- ------------ --------------
```

En la tabla anterior, se observa que, a mayor nivel de estudios, mayor probabilidad de contratar un depósito, por lo que se puede deducir que parece que existe una correlación positiva entre educación y las probabilidades de contratar un depósito a plazo.

Coeficiente de correlación lineal. Matriz de correlación

El coeficiente de correlación de Pearson es un índice que mide el grado de relación entre distintas variables cuantitativas relacionadas linealmente. Es importante recalcar que puede haber variables fuertemente relacionadas, pero no de forma lineal, en cuyo caso no debe aplicarse la correlación de Pearson.

Es un índice de fácil ejecución e interpretación. Sus valores absolutos oscilan entre 0 y 1.

- Correlación despreciable: rr < |0,1|
- Correlación baja: |0.1| < rr <= |0,3|
- Correlación mediana: |0.3| < rr <= |0,5|
- Correlación fuerte o alta: rr > |0,5|

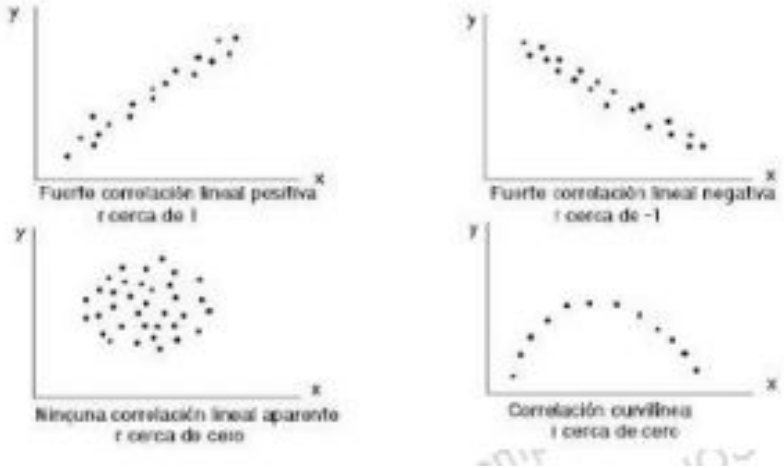
Coeficiente de correlación lineal. Matriz de correlación

El coeficiente de correlación de Pearson es un índice que mide el grado de relación entre distintas variables cuantitativas relacionadas linealmente. Es importante recalcar que puede haber variables fuertemente relacionadas, pero no de forma lineal, en cuyo caso no debe aplicarse la correlación de Pearson.

Es un índice de fácil ejecución e interpretación. Sus valores absolutos oscilan entre 0 y 1. Aunque en realidad puede tomar valores entre -1 y 1.

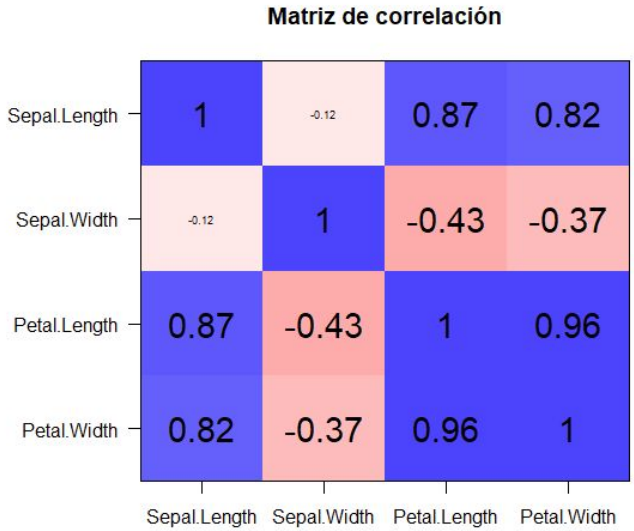
- Correlación despreciable: rr < |0,1|
- Correlación baja: |0.1| < rr <= |0,3|
- Correlación mediana: |0.3| < rr <= |0,5|
- Correlación fuerte o alta: rr > |0,5|

Coeficiente de correlación lineal. Matriz de correlación



Coeficiente de correlación lineal. Matriz de correlación

Una matriz de correlación es una matriz de muchas correlaciones.



Dependencia e independencia estadística

Entre dos variables o atributos puede ocurrir que exista independencia, dependencia funcional (matemática) o dependencia estadística.

Independencia

Cuando no se da ningún tipo de relación entre dos variables o atributos, es decir, cuando una de ellas no influye en la distribución de la otra condicionada por el valor que adopte la primera, se dice que son independientes. Ejemplo: peso y sueldo mensual de los trabajadores de un banco.

Dadas dos variables estadísticas X e Y, la condición necesaria y suficiente para que sean independientes son:

- Si X es independiente de Y, las distribuciones condicionadas de X/Yj son idénticas a la distribución marginal de X.
- Si X es independiente de Y, Y es independiente de X.
- Si X e Y son dos variables estadísticamente independientes, su covarianza es cero.

Dependencia funcional

Cuando existe una relación matemática exacta entre ambas variables, estas son dependientes funcionalmente.

El carácter X depende del carácter Y si a cada modalidad Yj de Y corresponde una única modalidad posible de X. Por lo tanto, cualquiera que sea j, la frecuencia absoluta nij vale cero salvo para un valor de i correspondiente a una columna j tal que nij = n.j.

Cada columna de la tabla de frecuencias tendrá, por consiguiente, un único término distinto de cero. Si a cada modalidad Xi de X corresponde una única modalidad posible de Y, Yserá dependiente de X. La dependencia de X respecto de Y no implica que Y dependa de X.

Ejemplo de variables con dependencia funcional: minutos de llamadas y factura mensual de un número de teléfono.

Dependencia estadística

Existen caracteres que ni son independientes, ni se da entre ellos una relación de dependencia funcional, pero sí existe una cierta relación de dependencia entre ambos: dependencia estadística.

Cuando los caracteres son de tipo cuantitativo, el estudio de la dependencia estadística se conoce como el problema de regresión, y el análisis del grado de dependencia que existe entre las variables se conoce como el problema de correlación.

Ejemplo de variables con dependencia estadística: peso y altura de un grupo de hombres de una misma población.

Dependencia estadística

¡Correlación no implica causalidad!

https://www.xataka.com/magnet/a-margarina-divorcios-11-divertidos-ejemplos-que-correlacion-no-implica-causalidad

Análisis de outliers

Se denomina así a aquellas observaciones cuyos valores son muy diferentes a las otras observaciones del mismo grupo de datos. El principal problema de la presencia de outliers es que pueden ser elementos no representativos de la población, lo que puede llegar a distorsionar los resultados de los modelos estadísticos.

Por otra parte, aunque diferentes a la mayor parte de la muestra, pueden ser indicativos de las características de un segmento válido de la población y, por consiguiente, una señal de la falta de representatividad de la muestra.

Análisis de outliers

Se pueden clasificar los outliers en dos tipos:

- **Valores erróneos**: Que surgen de un error de procedimiento, tales como la entrada de datos o un error de codificación. Estos casos atípicos deberían subsanarse en el filtrado de los datos, y si no se puede, deberían eliminarse del análisis o recodificarse como datos ausentes.
- **Valores atípicos**: Que ocurren como consecuencia de un acontecimiento extraordinario o por valores extremos pero reales. En este caso, los outliers representan información válida de la muestra y no deben ser eliminados. Sin embargo, es necesario evaluar la influencia que tienen estas observaciones en los modelos estadísticos. Para ello, es necesario replicar el análisis con y sin dichas observaciones con el fin de analizar su influencia sobre los resultados. Si dichas observaciones son influyentes, el analista debería reportarlo en sus conclusiones y debería averiguar el porqué de dichas observaciones.

Probabilidad y muestreo

Al realizar cualquier investigación social o de mercados, la mayor parte de las veces se rebasa la capacidad de los investigadores para llegar a toda la población o universo de estudio, por lo que se suele optar por métodos de muestreo que sirvan para acotar ese universo y así poder realizar la investigación dentro de nuestras posibilidades.

El conocimiento que se puede obtener de la población a partir de la muestra es limitado, pero resulta evidente que la aproximación a la realidad de la población será mejor cuanto más representativa sea la muestra. Para que esta sea representativa de la población, deben utilizarse técnicas de muestreo aleatorio, es decir: en las que los individuos se seleccionen al azar.

Conceptos básicos de muestreo

En ocasiones en que no es posible o conveniente analizar a todos los elementos de una población, se selecciona una muestra. Se entiende como tal a una parte representativa de la población. El fin será estudiarla para poder caracterizar el total de la población.

El muestreo: Es una herramienta de la investigación cuya función básica es determinar qué parte de una población debe examinarse para hacer inferencias sobre dicha población.

La muestra: Debe lograr una representación adecuada de la población de manera que reproduzca de la mejor manera las características esenciales de dicha población que son importantes para la investigación. Para que una muestra sea representativa, y por lo tanto útil, debe de reflejar las similitudes y diferencias encontradas en la población.

Conceptos básicos de muestreo

El muestreo es útil gracias a que puede acompañarse de un proceso inverso que se llama generalización de resultados. Es decir, para conocer un universo se hace lo siguiente:

1. Extraer una muestra del mismo.
2. Medir un dato u opinión.
3. Proyectar en el universo el resultado observado en la muestra.



Conceptos básicos de muestreo

La generalización de resultados añade cierto error al dato que medimos. El error cometido al generalizar resultados puede acotarse gracias a la estadística. Los errores más comunes que se pueden cometer son:

- **Error de muestreo:** Extraer conclusiones muy generales a partir de la observación de sólo una parte de la población.
- **Error de inferencia:** Extraer conclusiones sobre una población mucho más grande que de la que originalmente se tomó la muestra.

Tamaño de la muestra

Para que la muestra sea representativa, se seguirá un proceso de cálculo del tamaño teniendo en cuenta cuatro factores:

- **Tamaño de la población:** Cuanto más grande es una población, mayor será el tamaño de la muestra.
- **Heterogeneidad:** Hace referencia a la dispersión en alguna variable relevante en la investigación. Cuanto más heterogénea sea una población, mayor será el tamaño de la muestra.
- **Error muestral:** Hace referencia a cuánto varían los resultados de la muestra respecto del universo o población. Equivale a un rango de valores en el que se encuentra el resultado de la población. Lo escoge el investigador, aunque suelen ser en investigaciones sociológicas 3 % o 5 %. Cuanto menor sea el error muestral, más grande será el tamaño de la muestra, ya que para más precisión (menor error) se deberán estudiar más actores (más tamaño de la muestra).
- **Nivel de confianza:** Es la probabilidad que el resultado obtenido se encuentro dentro del intervalo de confianza. Se suelen utilizar niveles de confianza del 95 %.

Tamaño de la muestra

Ejemplo: se estudia una muestra usando un nivel de confianza del 95 % y se obtiene que la media de satisfacción de los clientes del banco con el servicio es 7 y la desviación estándar es 0,2. El intervalo de confianza del 95 % se expresa como la media +/- 2 desviaciones estándar, es decir: el intervalo irá entre aproximadamente 6,6 y 7,4. Es decir: hay un 95 % de posibilidades que el NPS del servicio de toda la población se encuentre en ese intervalo. Si se usan niveles de confianza mayores para ser más precisos, como el 99 %, el tamaño de la muestra será mayor.

PROBABILIDAD

Definición de probabilidad

¿Qué significa que la probabilidad de un resultado es 1 %, 10 %, 100 %, etc.?

Una forma de definir la probabilidad es a través de la noción de frecuencia relativa que se presentó en la unidad anterior. Si se lleva a cabo un experimento muchas veces (por ejemplo, lanzar un dado), entonces la proporción de veces que se produce un resultado particular (por ejemplo, un seis) se conoce como la frecuencia relativa. Si se repite el experimento un número muy grande de veces, entonces el valor límite de la frecuencia relativa (es decir, el valor al que se acerca la frecuencia relativa a medida que se acerca el número de veces a infinito) se denomina “probabilidad”.

Definición de probabilidad

Según la regla de Laplace, la probabilidad de A se calcularía como el cociente entre el número de casos favorables a A, y el de todos los posibles resultados del experimento:

$$P(A) = \frac{\text{número de casos favorables a A}}{\text{número de casos posibles}}$$

Experimentos y sucesos aleatorios

El estudio de una característica en una población se realiza a través de experimentos aleatorios.

Un experimento aleatorio es aquel en el que se conoce cuál es el conjunto de resultados posibles antes de su realización, pero se desconoce cuál será el resultado concreto del mismo.

Un ejemplo sencillo de experimentos aleatorios son los juegos de azar. Por ejemplo, el lanzamiento de un dado es un experimento aleatorio ya que se conoce el conjunto posible de resultados {1,2,3,4,5,6}. Antes de lanzar el dado, es imposible predecir con absoluta certeza el valor que saldrá.

Experimentos y sucesos aleatorios

Al conjunto E de todos los posibles resultados de un experimento aleatorio se le llama espacio muestral. Algunos ejemplos de espacios muestrales son:

- Lanzamiento de una moneda: E = {Cara, Cruz}.
- Lanzamiento de un dado: E = {1,2,3,4,5,6}.
- Grupo sanguíneo de un individuo seleccionado al azar: E = {A+, B+, AB+, 0+, A-, B-, AB, 0-}.

Experimentos y sucesos aleatorios

Un suceso aleatorio es cualquier subconjunto del espacio muestral E de un experimento aleatorio. Por ejemplo, el suceso aleatorio de seleccionar al azar un individuo que tenga grupo sanguíneo positivo es: {A+, B+, AB+, 0+}.

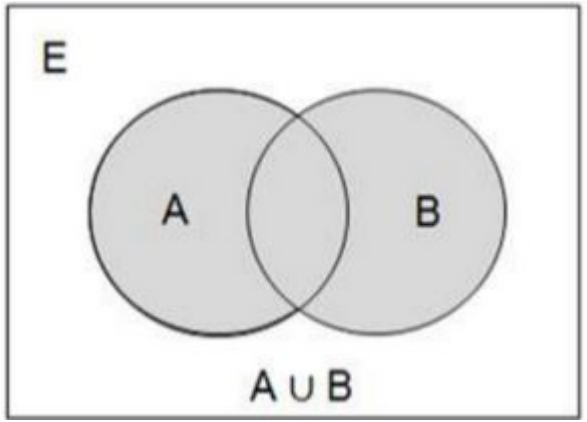
Preguntas

1. ¿Cuál la probabilidad de obtener un 1 al lanzar un dado?
2. ¿Cuál es la probabilidad de obtener un número impar al lanzar un dado?
3. ¿Cuál es la probabilidad de sacar un as en una baraja española? ¿Cuál es el espacio muestral?
4. En una urna hay 3 bolas rojas y 2 azules. Se extrae una al azar. ¿Cuál es el espacio muestral y la probabilidad de sacar una bola azul?

Operaciones entre sucesos

Unión de sucesos

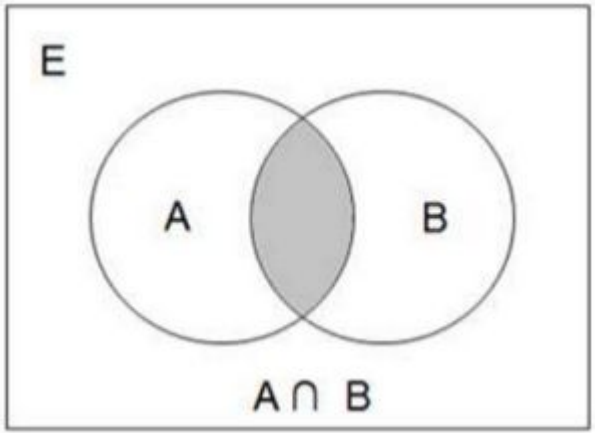
Dados dos sucesos A,B $\in$ P(E), donde P(E) es la probabilidad del espacio muestral E, se llama suceso unión de A y B, y se denota A $\cup$ B, al suceso formado por los elementos de A junto a los elementos de B.



Operaciones entre sucesos

Intersección de sucesos

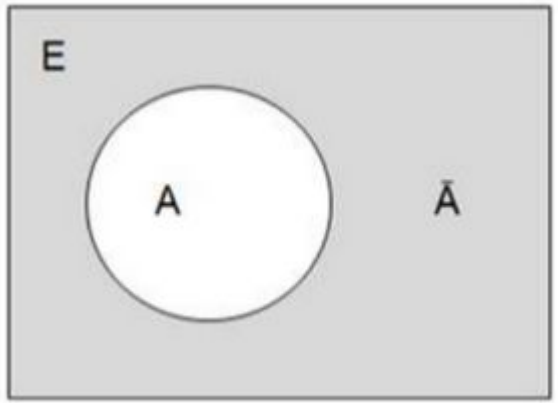
Dados dos sucesos A,B ∈ P(E), se llama suceso intersección de A y B, y se denota A ∩ B, al suceso formado por los elementos comunes de A y B. El suceso intersección A ∩ B ocurre siempre que ocurren A y B.



Operaciones entre sucesos

Contrario de un suceso

Un conjunto $A \in P(E)$, se llama suceso contrario o complementario de A, y se denota $\bar{A}$, al suceso formado por los elementos de P(E) que no pertenecen a A.



Axiomas de probabilidad

La probabilidad de los sucesos debe seguir los axiomas de la teoría de la probabilidad:

- La probabilidad de un suceso cualquiera es positiva o nula: $P(A) \geq 0$.
- La probabilidad de la unión de dos sucesos incompatibles es igual a la suma de las probabilidades de cada uno de ellos: $P(A \cup B) = P(A) + P(B)$.
- La probabilidad de todo espacio muestral es igual a la unidad: $P(E) = 1$.

Axiomas de probabilidad

A partir de los axiomas de la definición de probabilidad se pueden deducir numerosos resultados interesantes. Se destacarán dos:

- $P(\bar{A})=1-P(A)$
- $P(A \cup B)=P(A) + P(B) - P(A \cap B)$

Probabilidad condicionada

En algunas ocasiones puede que haya que calcular la probabilidad de algún suceso A sabiendo que ha ocurrido otro B. En tal caso, se dice que el suceso B es un condicionante, y la probabilidad del suceso condicionado suele escribirse como: P(A/B).

Los condicionantes, en el fondo, cambian el espacio muestral del experimento y, por tanto, las probabilidades de sus sucesos.

Probabilidad condicionada

Suponiendo que se han observado las siguientes frecuencias de solicitudes de tarjeta de crédito aceptadas en un grupo de 100 hombres y 100 mujeres:

	Aceptadas	Rechazadas
Mujeres	80	20
Hombres	60	40

Entonces, la probabilidad de que una persona elegida al azar haya recibido aceptación de tarjeta es P(Aprobado) = 140/200 = 0,7. Sin embargo, si se sabe que la persona elegida es mujer, entonces se tiene P(Aceptada/Mujer) = 80/100 = 0,8.

Probabilidad condicionada

Dados dos sucesos A y B de un mismo espacio de sucesos de un experimento aleatorio, la probabilidad de A condicionada por B es:

$$P(A/B) = \frac{P(A \cap B)}{P(B)}$$

Esta definición permite calcular probabilidades sin tener que alterar el espacio muestral original del experimento.

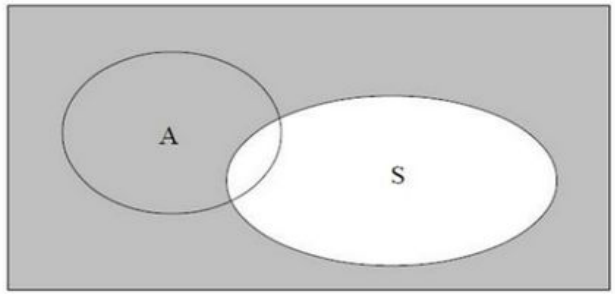
De esta definición se deduce que la probabilidad de la intersección es:

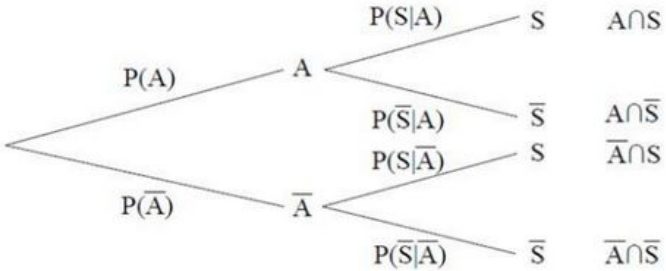
$$P(A \cap B) = P(A)P(B/A) = P(B)P(A/B)$$

Diagramas de árbol

Una buena forma de mostrar y calcular probabilidades condicionales simples es mediante el uso de un árbol de probabilidad. Los diferentes resultados están representados por las diferentes ramas del árbol.

Diagramas de árbol

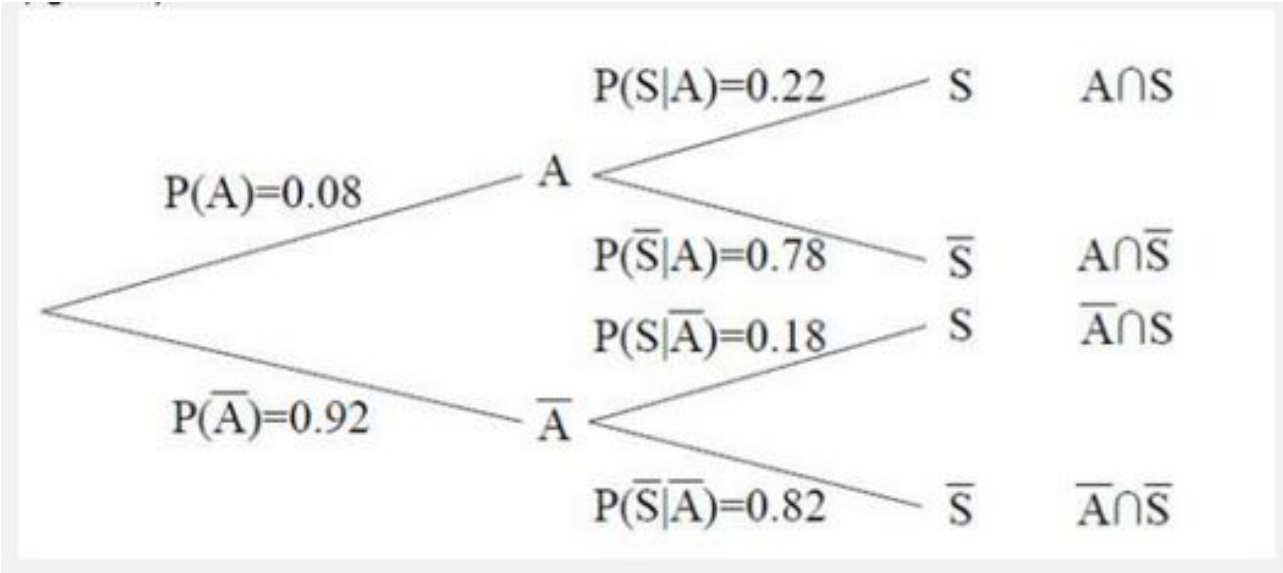




Diagramas de árbol

Por ejemplo, suponiendo que se está diseñando un modelo de riesgo para el cálculo de la tarifa de un seguro de vida, se sabe que en la población, la frecuencia de asma es del 8 % entre los adultos en general y que fuman el 22 % de los que padecen asma y fuman el 18 % de los que no padecen asma. Si S es fumador y A padece asma, se puede representar en un árbol de probabilidad. Ya se conoce P(A),P(S/A) y P (S/$\bar{A}$), por lo que la primera rama del árbol es para el estado de asma y la segunda rama es el estado de fumar condicional al estado de asma.

Diagramas de árbol



Diagramas de árbol

La probabilidad de cualquier intersección de asma y fumar se puede obtener multiplicando las probabilidades a lo largo de las ramas del árbol que conducen al extremo que corresponde a la deseada.

$P(A \cap S)=P(S)P(A/S) = 0.08 \times 0.22 = 0.018$

Es decir, menos del 2 % de la población padecen asma y son fumadores.

Sucesos dependientes e independientes

Si entre dos sucesos no existe ninguna relación, cabe esperar que la expresión “sabiendo que no” no aporte ninguna información (es decir, la ocurrencia de A no proporciona información sobre la ocurrencia B).

Sucesos dependientes e independientes

El concepto de independencia de dos sucesos A y B sería el siguiente:

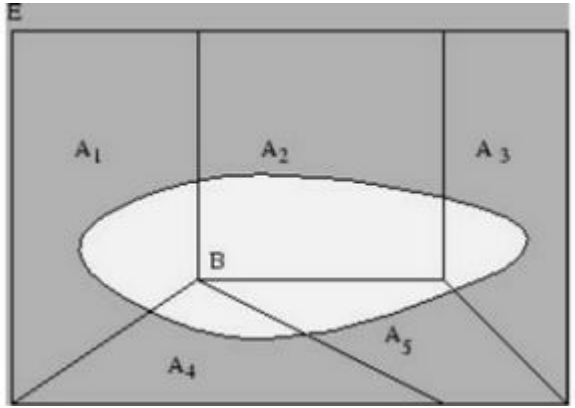
A es independiente de B$\leftrightarrow P(A \cap B)=P(A)P(B)$

Esta relación puede ser escrita de modo equivalente: dados dos sucesos de probabilidad no nula (de manera que $P(A)\neq 0\neq P(B)$) se dirá que A es independiente de B si y sólo si $P(B)=P(B/A)$ o equivalentemente $P(A)P(A/B)$.

Así, se dice que dos experimentos son independientes si los resultados de uno son independientes de los del otro para cualquier par de resultados que se escoja.

Fórmula de la probabilidad total

Sea A1 , A2 , ..., An ⊂ E un sistema exhaustivo y mutuamente excluyente de sucesos.



Fórmula de la probabilidad total

Entonces, B $\subset$ E, se verifica que

$$P(B) = P(B/A_1)P(A_1) + P(B/A_2)P(A_2) + \cdots + P(B/A_n)P(A_n)$$

$$= \sum_{i=1}^{n} P(B/A_i)P(A_i)$$

Es decir, la probabilidad de que ocurra el suceso B es igual a la suma de multiplicar cada una de las probabilidades condicionadas de este suceso con los diferentes sucesos A por la probabilidad de cada suceso A.

Fórmula de la probabilidad total

Ejemplo: Para calcular la probabilidad total de ser fumador, se puede usar el teorema de la probabilidad total, ya que los eventos de “sufrir asma” o “no” forman una partición del espacio muestral.

$P(S)=P(S/A)P(A)+P(S/\overline{A})P(\overline{A})=0,22 \times 0,08+0,18 \times 0,92=0,188$

En otras palabras, la probabilidad total de ser fumador es igual a la suma de ser fumador entre los que tienen asma multiplicado por la probabilidad de tener asma más la probabilidad de ser fumador entre aquellos que no los tienen multiplicado por la probabilidad de no tener asma.

Teorema de Bayes

El teorema de Bayes es utilizado para calcular la probabilidad de un suceso, teniendo información a priori sobre ese suceso.

Se puede calcular la probabilidad de un suceso A si se sabe, además, que ese A cumple cierta característica que condiciona su probabilidad.

Entiende la probabilidad de forma inversa a la fórmula de la probabilidad total. La probabilidad total hace inferencia sobre un suceso B a partir de los resultados de los sucesos A. Por su parte, Bayes calcula la probabilidad de A condicionado a B.

Teorema de Bayes

Dado un sistema completo de sucesos A1 , ..., An y un suceso B de un mismo espacio de sucesos, se cumple:

$$P(A_i/B) = \frac{P(B/A_i)P(A_i)}{\sum_{i=1}^{n} P(B/A_i)P(A_i)}$$

El teorema de Bayes es una consecuencia de la definición de probabilidad condicionada en términos de la intersección y del teorema de la probabilidad total que se ha visto en puntos anteriores:

$$P(A_i/B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B/A_i)P(A_i)}{\sum_{i=1}^{n} P(B/A_i)P(A_i)}$$

Teorema de Bayes

Volviendo al ejemplo del asma y el tabaquismo, se conoce la probabilidad de padecer asma y la probabilidad de ser fumador condicional a padecer asma o no. Para que tenga utilidad en el caso de negocio para el cálculo de primas de riesgo, se necesita calcular cómo fumar afecta el riesgo de asma, es decir: para hacer una declaración sobre la probabilidad de padecer asma condicionado a ser fumador

Para un fumador, aplicando el teorema de Bayes, la probabilidad de padecer asma es:

$$P(A/S) = \frac{P(S/A)P(A)}{P(S/A)P(A) + P(S/\bar{A})P(\bar{A})} = \frac{0{,}22\ x\ 0{,}08}{0{,}22\ x\ 0{,}08 + 0{,}18\ x\ 0{,}92} = 0{,}096$$

Ejercicios

1. Hay **3 cajas** elegidas al azar (probabilidad 1/3 cada una):

Caja A: 2 bolas rojas y 1 azul.

Caja B: 1 roja y 2 azules.

Caja C: 3 azules.

Se elige una caja al azar y se extrae una bola que resulta **roja**. ¿Cuál es la probabilidad de que la caja elegida haya sido la **A**?

2. El 20% de los correos que llegan son spam. Un filtro marca como spam con probabilidad **0.90** cuando el correo es spam y marca como spam con probabilidad **0.05** cuando el correo **no** es spam.

Si un correo está marcado como spam por el filtro, ¿qué probabilidad hay de que realmente sea spam?

Ejercicios

3. En una población, la **Enfermedad A** tiene prevalencia 2% y provoca el síntoma S con probabilidad 0.7 (P(S|A)=0.7). La **Enfermedad B** tiene prevalencia 1% y provoca el mismo síntoma con probabilidad 0.5. Se asume que A y B son mutuamente excluyentes (una persona no puede tener A y B simultáneamente) y que si no tiene A ni B la probabilidad de S es 0.1.

Si una persona presenta el síntoma S, ¿cuál es la probabilidad de que tenga la **Enfermedad A**?

4.1. En una urna hay 4 bolas rojas y 6 bolas azules (10 en total). Se extraen **dos bolas**, **con reemplazo** (es decir, después de la primera extracción la bola vuelve a la urna). Calcula:

a) P(ambas rojas).
b) P(una roja y una azul, en cualquier orden).
c) P(al menos una azul).

4.2. Calcula más probabilidades pero considera que esta vez se extraen las **dos bolas sin reemplazo**.

Distribuciones de probabilidad

Cuando se selecciona una muestra al azar de una población, se está realizando un experimento aleatorio y cualquier variable estadística medida a partir de la muestra será una variable aleatoria porque sus valores dependen del azar.

Una **variable aleatoria X** es una función que asocia un número real a cada elemento del espacio muestral de un experimento aleatorio. Al conjunto de posibles valores que puede tomar la variable aleatoria se le llama rango o recorrido de la variable. En el fondo, una variable aleatoria es una variable cuyos valores provienen de la realización de un experimento aleatorio y, por tanto, tendrá asociada una determinada distribución de probabilidad.

Un ejemplo de variable aleatoria es la que mide el resultado del lanzamiento de un dado o, por ejemplo, la altura o el gasto en tarjeta de crédito.

Distribuciones de probabilidad

La mayoría de los fenómenos de la naturaleza siguen exacta o aproximadamente una serie de distribuciones de probabilidad teóricas bien definidas, siendo las principales las siguientes:

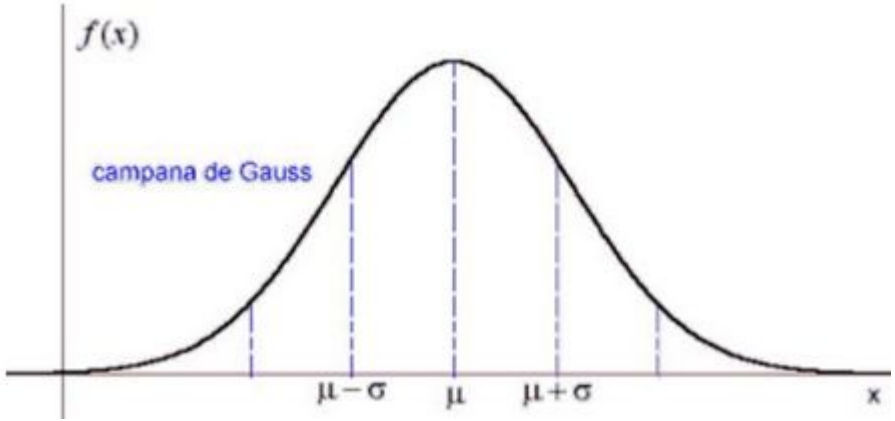
- Distribución normal.
- Distribución binomial.
- Distribución de Poisson.

Distribución normal

Es la distribución más importante en estadística, ya que numerosas variables asociadas a fenómenos naturales siguen, aproximadamente, una distribución normal, es decir: una vez calculada su distribución, se observa que es normal (ejemplo: estatura o peso). Tiene forma de campana y es simétrica respecto a su media. También es conocida como campana de Gauss en honor a su descubridor.

Está determinada por dos parámetros: la Media (μ) y la desviación estándar (σ), tal y como se muestra a continuación:

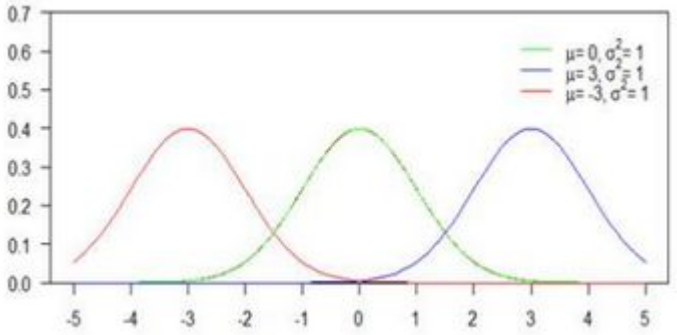
Distribución normal



Distribución normal

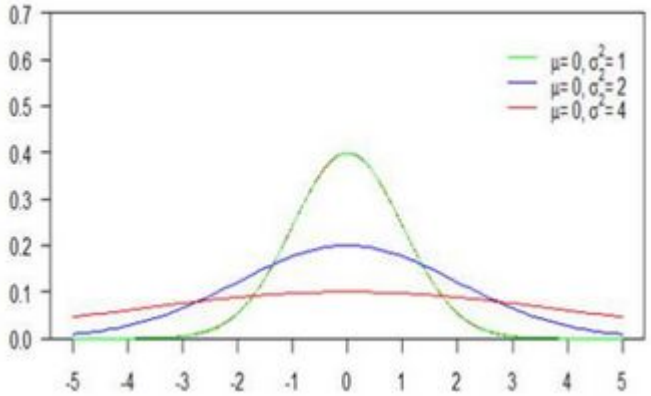
La Media (μ) determina la posición relativa de la curva en el eje horizontal. En el eje vertical se representa la probabilidad asociada a cada valor de X.

Si la media aumenta la distribución se desplaza a la derecha; si la media disminuye, la distribución se desplaza hacia la izquierda.



Distribución normal

Si la desviación típica aumenta la altura disminuye y la curva se ensancha; su la desviación estándar disminuye, la altura aumenta y la curva se ensancha.



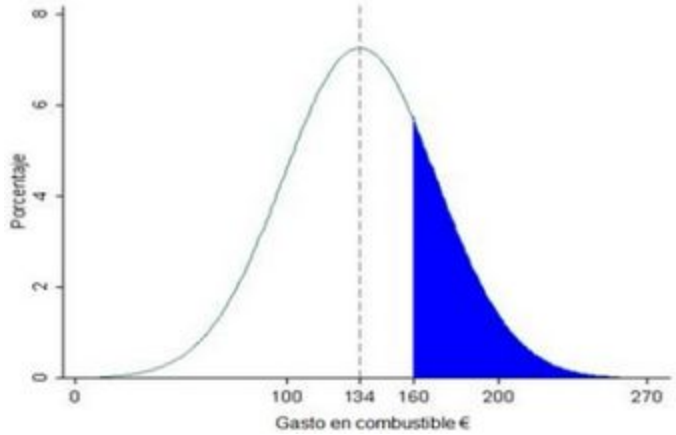
Distribución normal

Una vez caracterizada la distribución de una variable, se pueden calcular probabilidades asociadas a la ocurrencia de la variable.

Ejemplo: se ha realizado un estudio para medir el gasto mensual en combustible de un grupo de personas. Se sabe que la distribución del gasto en combustible es normal con media (μ) 134 € y desviación estándar (σ) 36 €.

Se necesita determinar el porcentaje de individuos de esta población que tienen un gasto mensual en combustible superior a 160 € (o, equivalentemente, la probabilidad de que un individuo de esta población tenga un gasto mensual en combustible superior a 160 €). Para calcular este porcentaje, basta con determinar el área bajo la curva de una normal (μ = 134, σ = 36) que está por encima del valor 160, tal y como se muestra a continuación:

Distribución normal



El cálculo de esta área se haría integrando entre 160 e infinito la función que define la curva de una normal ($\mu = 134$, $\sigma = 36$).

Distribución normal

Afortunadamente, se puede utilizar un procedimiento alternativo basado en la distribución normal estándar para llevar a cabo este cálculo. La distribución normal estándar es una distribución normal con media 0 y desviación estándar 1.

Los valores de la distribución normal estándar se denominan puntuaciones z (valores tipificados). Es posible transformar cualquier variable con distribución normal de media μ y desviación estándar σ en una distribución normal estándar mediante la siguiente fórmula:

$$z = \frac{x - \mu}{\sigma}$$

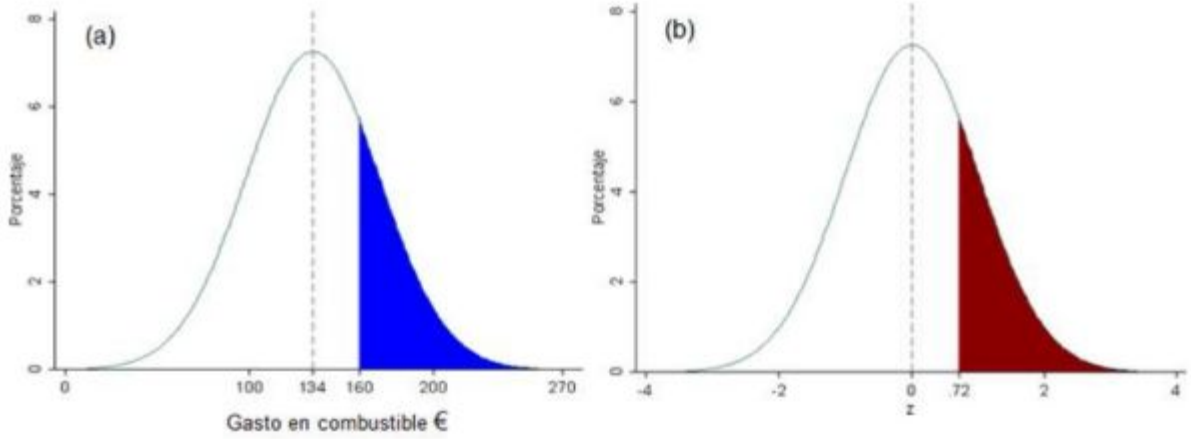
Distribución normal

En el ejemplo anterior se quería determinar el porcentaje de individuos de la población con gasto en combustible superior a 160 €. Para calcular este porcentaje, basta con determinar el área bajo la curva de una normal (μ = 134, σ = 36) que está por encima del valor 160. Para determinar esta área, calculamos la puntuación z correspondiente al valor 160 de una distribución normal (μ = 134, σ = 36). Para ello, al valor 160 se le resta la media y se divide entre la desviación estándar:

$$z = \frac{160 - 134}{36} = 0{,}72$$

Distribución normal

El área bajo la curva de una normal (μ = 134, σ = 36) que está por encima del valor 160, (a) es exactamente igual que el área bajo la curva de una normal estándar que está por encima del valor 0,72, (b).



Distribución normal

Para calcular la probabilidad de un suceso que sigue la distribución normal estándar se puede usar una única tabla. En caso contrario habría que utilizar una tabla por cada distribución con media y desviación estándar distintas.

Si usamos la tabla de la distribución normal estándar podemos ver la probabilidad la probabilidad $P(Z <= z) = 0.7642$, pero la que a nosotros nos interesa es $P(Z>z)$, que es el suceso contrario y se puede calcular con la fórmula de la probabilidad inversa.

$$P(Z>z)=1-P(Z<=z)= 1-0.7642=0.2358$$

Distribución binomial

La distribución binomial emerge si el interés se centra en determinar el número (o proporción) de individuos de entre n observados que verifican una cierta característica dicotómica (ej. vivo o muerto) y existe la probabilidad de que cada individuo verifique la característica, igual para todos los individuos.

La fórmula general para calcular la probabilidad de observar exactamente x eventos en una muestra de n individuos. P es la probabilidad de que cada individuo experimente el evento.

$$P(x\ eventos) = \frac{n!}{x!\,(n-x)!} p^x (1-p)^{n-x}$$

Distribución binomial

La primera parte de la fórmula representa el número posible de situaciones en las que pueden ocurrir x eventos entre los n individuos observados; y la segunda parte de la fórmula representa la probabilidad de que cada una de las situaciones ocurra. La exclamación (!) denota el factorial de un número:

n! = n · (n-1) · (n-2) · (n-3) · 1

0! = 1

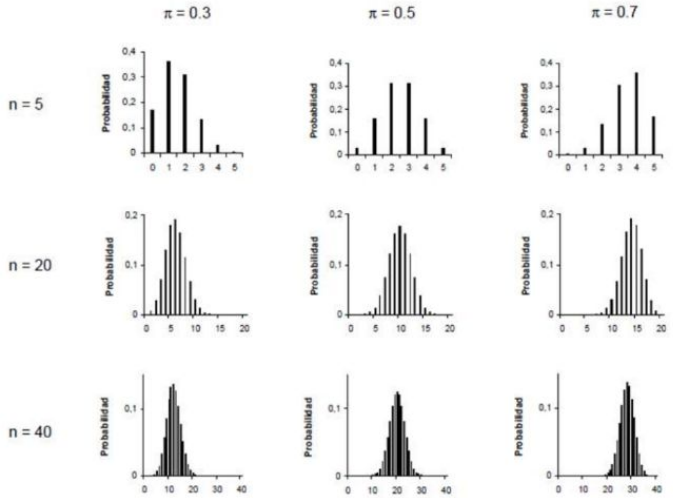
La media y la desviación estándar es:

$$media = \mu = np$$

$$desviación\ estándar = \sigma = n\sqrt{p(1-p)}$$

Distribución binomial

Conforme aumenta el tamaño de la muestra n, la distribución binomial se aproxima a la distribución normal tal y como se observa en la siguiente figura.



Distribución de Poisson

La distribución de Poisson es apropiada para describir:

- El número de ocurrencias de un evento durante un período de tiempo, siempre y cuando los eventos ocurran independientemente unos de otros y de forma aleatoria.

  Ejemplo: número de llamadas que recibe una central telefónica en una hora; número de pólizas de seguro vendidas, durante un año, en una compañía

- El número de partículas encontradas en una unidad de espacio, siempre y cuando las partículas se distribuyan aleatoria e independientemente en el espacio total.

  Ejemplo: el número de defectos por metro cuadrado de tela, número de estrellas en un determinado volumen de espacio.

Distribución de Poisson

La fórmula general para calcular la probabilidad de observar exactamente x ocurrencias de un evento durante un período de tiempo (o región de espacio) es:

$$P(x\ ocurrencias) = e^{-\lambda}\frac{\lambda^x}{x!}$$

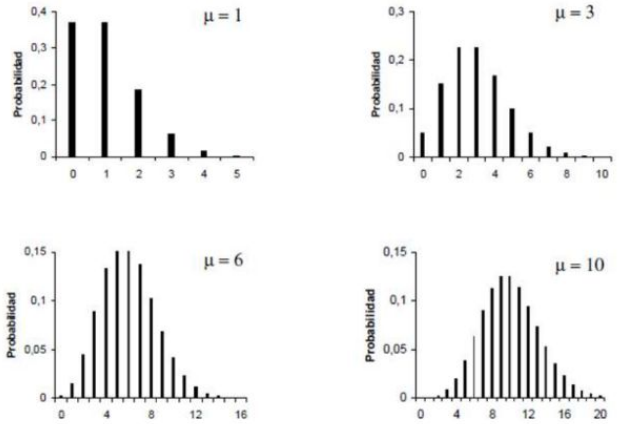
λ es el número medio de ocurrencias de un evento en períodos de tiempo de la misma longitud (o en iguales regiones de espacio). Su media y desviación estándar:

$$media = \mu = \lambda$$

$$desviación\ estándar = \sigma = \sqrt{\lambda}$$

Distribución de Poisson

Conforme aumenta la media de la distribución de Poisson, μ, la distribución de Poisson se aproxima a la distribución normal tal y como se observa en la siguiente figura.



Ejercicios

1. La temperatura durante septiembre está distribuida normalmente con media 18,7ºC y desviación standard 5ºC. Calcula la probabilidad de que la temperatura durante septiembre esté por debajo de 21ºC y la probabilidad de que esté por encima.

2. La media de los pesos de 5000 estudiantes de un colegio es 70 kg y la desviación típica 3 kg. Suponiendo que los pesos se distribuyen normalmente, hallar cuántos pesan:

1. Entre 60 y 75 kg.
2. Más de 90 kg.
3. Menos de 64 kg.
4. 64 kg.
5. 64 kg o menos.

Ejercicios

3. Varios test de inteligencia dieron una puntuación que sigue la distribución normal con media 100 y desviación típica 15.

1. Determina el porcentaje de la población que obtendría un coeficiente entre 95 y 110.
2. En una población de 2500 individuos, ¿cuántos individuos se esperan que tengan un coeficiente superior a 125?
3. ¿Qué CI hay que tener para tener un CI superior al 80% de la población?

Inferencia

Introducción

La inferencia estadística plantea un problema opuesto al del tema anterior, que trataba sobre cómo calcular la probabilidad de ciertos sucesos aleatorios y elegir una muestra representativa de la población. Tiene como objetivo obtener conclusiones de la población de estudio a partir de la información proporcionada por la muestra seleccionada.

Por ejemplo, si se quiere estimar la media de los ingresos anuales de los españoles y se selecciona una muestra de 100 personas: ¿qué valor se utiliza para estimar la media poblacional? Si la media de la muestra es 1 200 €, se puede afirmar que la media poblacional es “aproximadamente 1 200 €”. Sin embargo, no se puede decir que el valor de la media poblacional sea exactamente 1 200 € ya que habitualmente la media poblacional no coincide exactamente con la media muestral.

Introducción

A la estimación realizada a través de la muestra se le llamará “estimación puntual”. Los estimadores puntuales solo dan una idea aproximada del verdadero valor del parámetro a estimar, sin saber cómo de fiable es tal aproximación. Sin embargo, habitualmente se realizan afirmaciones sobre la población general con cierto nivel de confianza (fijada previamente) a través de los intervalos de confianza y los contrastes de hipótesis.

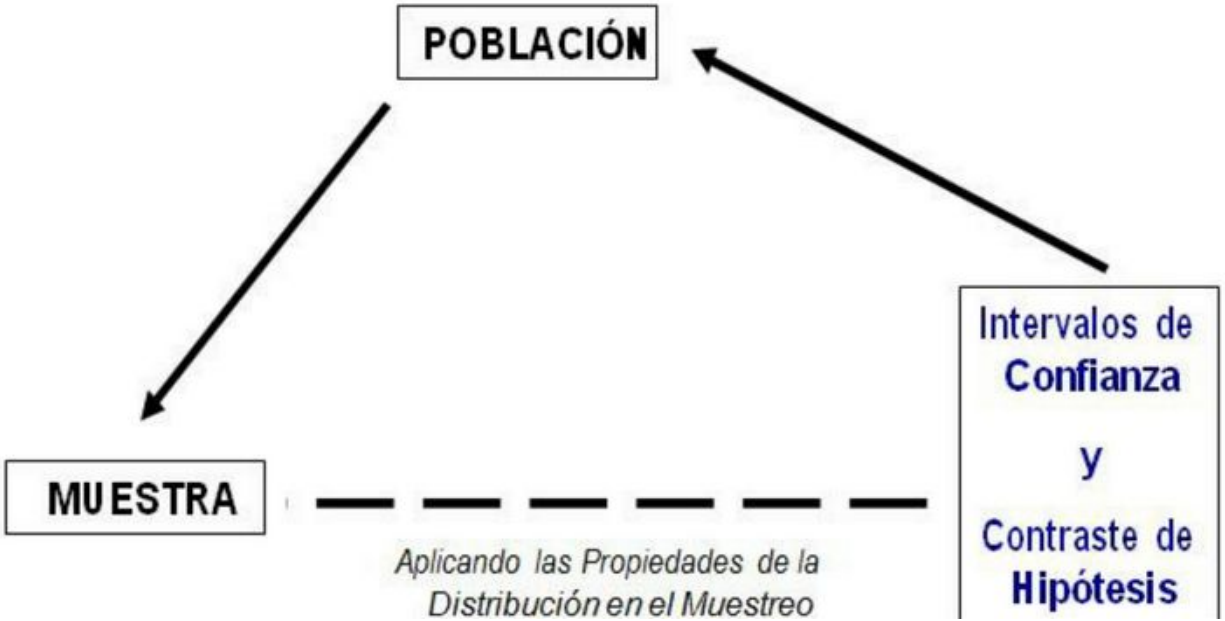
Intervalo de confianza

Rango de valores entre los cuales se puede asegurar que se encuentra un parámetro de la población con cierto nivel de confianza prefijado.

Contraste de hipótesis

Procedimiento que permite sacar conclusiones acerca de una hipótesis sobre un parámetro de la población con cierto nivel de confianza prefijado.

Introducción



Intervalos de confianza

La estimación por intervalos trata de construir a partir de la muestra un intervalo dentro del cual se supone que se encuentra el parámetro a estimar con un cierto grado de confianza. Para ello, se utilizan dos estimadores, uno para el límite inferior del intervalo y otro para el límite superior. Estos límites se calculan a través de los estadísticos obtenidos en la muestra (por ejemplo: la media y la desviación estándar) que tienen una distribución en el muestreo.

El **nivel de confianza**, expresado como un porcentaje, se define como la probabilidad a priori de que el intervalo basado en la muestra seleccionada contenga el verdadero valor de la población. En otras palabras: si se repitiese el proceso de muestreo infinitas veces, el nivel de confianza sería la proporción de intervalos que contendrían el valor verdadero de parámetro poblacional.

Intervalos de confianza

Para que un intervalo sea útil, su nivel de confianza debe ser alto:

$1 - \alpha = 0{,}90$ o $\alpha = 0{,}10$

$1 - \alpha = 0{,}95$ o $\alpha = 0{,}05$

$1 - \alpha = 0{,}99$ o $\alpha = 0{,}01$

Siempre que 0,95 (95 %) sea el nivel de confianza más común y 0,99 (99 %) en casos críticos.

Cuando un intervalo calculado es amplio, implica que los datos han proporcionado poca información sobre el parámetro, mientras que un intervalo estrecho resulta de los datos que proporcionan información más precisa sobre el parámetro.

Intervalos de confianza

Por ejemplo, el intervalo de confianza del 95% para la media de una población grande que sigue la distribución normal se calcularía con la siguiente fórmula:

$$IC_{95\%}(\mu) = \bar{x} \pm (1.96 \times s / \sqrt{n})$$

Contraste de hipótesis

En muchas ocasiones, el objetivo de un análisis estadístico será verificar, basándose en la información de la muestra, una hipótesis formulada sobre un parámetro de la población de estudio. Por ejemplo, el objetivo es verificar si el gasto familiar en alimentación de una familia es igual a 200 €.

Para comprobar la veracidad o falsedad de estas hipótesis, hay que contrastarlas con los resultados obtenidos de las muestras. Si los resultados observados en las muestras coinciden, dentro de un margen de error admisible, con lo que cabría esperar en caso de que la hipótesis fuese cierta, la hipótesis se aceptará como verdadera, mientras que en caso contrario se rechazará por ser falsa y se buscarán nuevas hipótesis capaces de explicar los datos observados.

Como las muestras se obtienen aleatoriamente, la decisión de aceptar o rechazar una hipótesis estadística se tomará sobre una base de probabilidad.

Contraste de hipótesis

El primer paso en la realización de un contraste de hipótesis es el planteamiento de las hipótesis.

En la mayoría de los casos un contraste supone tomar una decisión entre dos hipótesis antagonistas:

Hipótesis nula

La hipótesis nula H0 es la hipótesis de partida (la que se contrasta). Debe recoger el hecho que se quiera someter a prueba. La hipótesis nula se suele plantear en términos de igualdad:

Hipótesis alternativa

La hipótesis alternativa H1 es la que, como su nombre indica, se ofrece como alternativa a la nula. Esta hipótesis, representa que se ha producido un cambio con respecto a la situación descrita por la hipótesis nula.

Contraste de hipótesis

Una vez planteadas la hipótesis nula y alternativa, se debe tomar una decisión a partir de las observaciones.

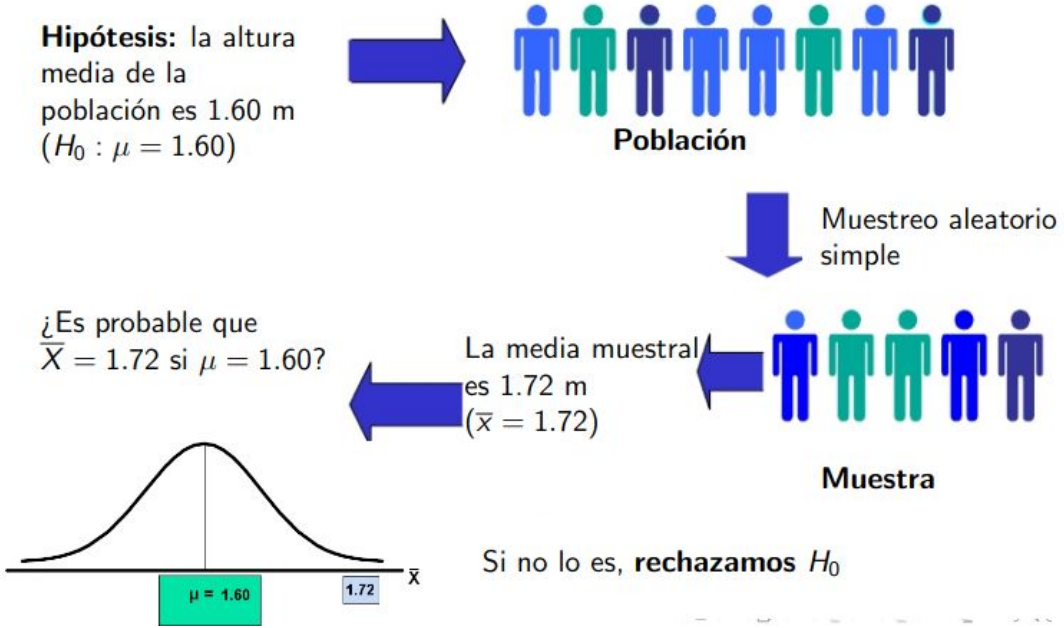
Existen dos decisiones posibles:

- Aceptar la hipótesis nula.
- Rechazar la hipótesis nula.

Esto hace que, una vez realizado el contraste de hipótesis, se puedan cometer dos clases de errores diferentes:

- Aceptar la hipótesis nula cuando es falsa.
- Rechazar la hipótesis nula cuando es cierta.

Contraste de hipótesis



Contraste de hipótesis

Un contraste de hipótesis es una regla que determina, a un cierto nivel de significación, α, para qué valores de la muestra se rechaza o no se rechaza la hipótesis nula.

Se trata de determinar, a un nivel de significación α, una región crítica o de rechazo, RCα, y una región de aceptación, RAα.

